

Análisis y Ciencia de Datos

Proyecto 1 (Examen Parcial 2)

Facultad de Ingeniería, Universidad del Istmo de Guatemala

Guatemala, 24 de agosto de 2026

Fecha de entrega: 24 de septiembre de 2026

1 Introducción

En esta ocasión vamos a poner en práctica todo lo que hemos aprendido de la teoría de probabilidades, además de la investigación que realizaron sobre generadores de números pseudoaleatorios y simulaciones de Monte Carlo. La temática del proyecto consiste en estimar la probabilidad de eventos deportivos altamente improbables y contar la historia detrás de estos momentos que han marcado las memorias de millones de fanáticos a lo largo de los años.

2 Eventos a simular

En grupos, elijan uno de los siguientes eventos para su presentación.

2.1 “It’s eleven, it’s heaven for Jamie Vardy!”

Es la temporada 2015-16 de la Premier League. El Leicester City, habiendo sobrevivido a su primera temporada tras el ascenso a primera división, contrata a Claudio Ranieri luego del despido de Nigel Pearson. En medio del escepticismo general, el equipo de Ranieri arranca la temporada de manera espectacular, liderado por su delantero y talismán Jamie Vardy. En el periodo de agosto a noviembre de 2015, Vardy anotó 13 goles en 11 partidos consecutivos y rompió el récord de Ruud van Nistelrooy, quien había anotado en 10 partidos consecutivos. Todo esto sirvió de preámbulo para el hito más improbable en la historia del fútbol inglés: el modesto Leicester ganando la liga.

2.1.1 Instrucciones

Habiendo establecido el escenario, deberán realizar lo siguiente:

1. Utilizando <https://understat.com/>, <https://fbref.com/en/> o una base de datos de tu preferencia, estima la tasa de goles por partido de Vardy para:
 - (a) La temporada 2014-15 (su primera temporada en la Premier League).
 - (b) La temporada 2013-14 (su última temporada en el Championship).

Por ejemplo, en la temporada en la que el Leicester ganó la liga, Harry Kane anotó 25 goles en 38 partidos, obteniendo una tasa de 0.657 goles por partido.

2. Con las tasas de goles por partido de Vardy, estima de forma simple la probabilidad de anotar en 11 partidos consecutivos con una distribución de Bernoulli.
3. Ahora, estima la probabilidad de alcanzar esta racha utilizando una cadena de Markov. Es decir, si los partidos $X_1, \dots, X_n$ son eventos independientes en los que Vardy tiene éxito (e.g., anota) con probabilidad p y fracasa con probabilidad $1 - p$, defínase:

$$A = \{\text{al menos una racha de } K \text{ éxitos consecutivos en } n \text{ partidos}\}$$

Supón que hemos observado los primeros t partidos y que la racha actual es de tamaño j . Para calcular la probabilidad de que aparezca una racha de tamaño K , basta con tomar en cuenta la longitud de la racha actual, y no la cantidad total de éxitos observados hasta el momento t . Si tenemos éxito, la racha aumenta a tamaño $j + 1$; en caso contrario se reduce a 0. Sea $S_t \in \{0, 1, \dots, K\}$, donde:

- $S_t = j$, $0 \leq j \leq K - 1$ representa “la racha de tamaño K aún no ocurre, pero la racha actual es de tamaño j ”.
- $S_t = K$ es el estado terminal y representa “una racha de tamaño K ya ocurrió”, porque A solo necesita que la racha ocurra, no que nos encontremos en una en este momento.

Construye las probabilidades de transición (éxito: $j \rightarrow j + 1$ con probabilidad p ; fracaso: $j \rightarrow 0$ con probabilidad $1 - p$; K es absorbente) e itera sobre los n partidos. La probabilidad buscada es $\mathbb{P}(A) = \mathbb{P}(S_n = K)$.

4. Compara tus resultados de los incisos 2 y 3. Explica por qué la estimación con la distribución de Bernoulli falla y encuentra un caso en el que utilizar esta distribución no tenga sentido.
5. Como comentamos al inicio de esta sección, van Nistelrooy estableció el récord original en 2003 y Vardy lo rompió 12 años después. Esto nos lleva a la siguiente pregunta: **¿podrá alguno de los delanteros de la Premier League igualar o romper el récord?** (i.e., $K \geq 11$). Utiliza una simulación de Monte Carlo para estimar la

probabilidad de que los 10 mejores delanteros jóvenes de la liga (26 años o menos) puedan romper el récord en los próximos 15 años, tomando como base su tasa de goles por partido en la temporada más reciente.

Dos (2) puntos extra: en vez de dejar fija la tasa de goles por partido, estima la probabilidad de A con una tasa distinta para cada partido (e.g., utilizando la tasa de goles recibidos por el rival del Leicester en el partido correspondiente). Compara tus resultados.

2.2 “I think I’m a special one”

En la temporada 2004-05 de la Premier League, el Chelsea Football Club acababa de contratar a *the special one*, José Mourinho. Con los fondos aportados por el nuevo dueño del club, Roman Abramovich, Mourinho armó probablemente la defensa más impenetrable de toda la historia del fútbol. Petr Čech, Ricardo Carvalho, John Terry, Paulo Ferreira y William Gallas llevaron al Chelsea a ganar su primera liga en 50 años, recibiendo **únicamente 15 goles**, un récord que hasta el día de hoy no ha podido ser superado.

2.2.1 Instrucciones

Dado que ningún equipo se ha acercado al récord en más de 20 años, trataremos de estimar si algún día alguien podrá lograrlo:

1. Utilizando los datos de www.football-data.co.uk, obtén la cantidad de goles en contra de los campeones de la Premier League desde la temporada 1995-96 hasta la temporada 2025-26.
2. Utilizando una distribución de tu preferencia, estima:

$$p = \mathbb{P}(\text{el campeón recibe } \leq 14 \text{ goles})$$

Sugerencia: empieza con una distribución de Poisson y luego investiga acerca de la **distribución binomial negativa**.

3. Habiendo estimado p , sabemos que podemos modelar el número de temporadas hasta el primer éxito (es decir, hasta que un campeón reciba 14 goles o menos) con una distribución geométrica, por lo que la probabilidad de que alguien rompa el récord en N años es $1 - (1 - p)^N$. Estima la probabilidad de que alguien rompa el récord en $N = 20, 50, 100, 200, 1000$ años.
4. Ahora, en lugar de utilizar los goles en contra del campeón, busca la mejor defensa de cada temporada y estima “un equipo que conceda 14 goles o menos aparece cada R años” (ten en cuenta que romper el récord exige, además, que ese equipo sea el campeón). Para ello, utiliza la teoría de valores extremos (distribución GEV). Un par de recursos valiosos:

- Block Maxima Guide

- Example GEV Analysis with Confidence Intervals
- Un primer ejemplo

Nota: la GEV por lo general busca máximos, y acá necesitamos buscar *mínimos*.

Como solo cuentas con ~ 30 temporadas, tu estimado puntual de R es **inestable**: un solo número esconde una enorme incertidumbre. Por ello, reporta un **intervalo de confianza** para R (y para el parámetro de forma ξ) mediante *bootstrap*:

- Remuestrea las temporadas **con reemplazo** para formar una muestra del mismo tamaño que la original.
- Reajusta la GEV sobre esa muestra y calcula R y ξ .
- Repite los pasos (a)–(b) muchas veces (por ejemplo, 2000) y toma los percentiles 5 y 95 de los valores obtenidos.

Reporta tu resultado como **mediana [IC 90%]** en lugar de un único número (por ejemplo, “ $R \approx 150$ años [IC 90%: 40–250]”).

5. Compara tus resultados de los incisos 3 y 4 y responde: **¿qué tan a salvo está este récord?** En tu respuesta, apóyate en el **ancho del intervalo de confianza** del inciso 4: un intervalo muy amplio significa que, con tan pocos datos, ni siquiera podemos afirmar con precisión cuán improbable es romper el récord. Discute qué implica esto para la confiabilidad de tu conclusión.

Tres (3) puntos extra: utiliza una distribución de Pareto generalizada para ajustar los valores de las mejores defensas y compara el valor del parámetro ξ de esta distribución con el obtenido en el inciso 4. ¿Cuál de los métodos consideras más confiable y por qué?

2.3 Neverkusen no more

Ahora, conmemoremos un evento un poco más reciente. Después de 11 temporadas seguidas de dominio absoluto del Bayern Múnich, en la temporada 2023-24 el Bayer Leverkusen hizo lo impensable: ganar la Bundesliga. Y no solo eso, **lo lograron sin perder un solo partido**. Claro, ha habido equipos invictos como el Arsenal en 2004 o la Juventus en 2012, pero hacerlo en una liga donde un equipo ha dominado durante buena parte de los últimos 30 años es aún más impresionante.

2.3.1 Instrucciones

Analicemos la proeza de los dirigidos en ese entonces por Xabi Alonso:

1. Primero, obtén los datos de los campeones de la Bundesliga desde 1964 hasta 2023.
2. Con esto, calcula empíricamente la probabilidad de que un equipo que no sea el Bayern Múnich gane la Bundesliga. Luego, compara con la probabilidad restringiendo el rango de tiempo de 2005 a 2023.
3. Luego, obtén el ranking Elo de los clubes de la Bundesliga para la temporada 2023-24 utilizando <http://clubelo.com/>.
4. Como la temporada de Bundesliga consta de 34 partidos, y tomando en cuenta el dominio del Bayern Múnich, estima la siguiente probabilidad:

$$\mathbb{P}(\text{invicto}) = \mathbb{P}(\text{no perder 2 partidos contra el Bayern}) \times \mathbb{P}(\text{no perder los otros 32 partidos})$$

5. Simula 10,000 temporadas utilizando Monte Carlo para visualizar lo improbable de este evento.
6. Ahora, en vez de modelar los partidos de esa temporada, analiza el rendimiento histórico de un campeón. Utilizando una distribución de Poisson (o binomial negativa), estima la probabilidad de que un campeón obtenga 0 derrotas a lo largo de una temporada. Dado que el Bayern es el máximo ganador histórico de la competición, compara la probabilidad de que el Bayern lo logre con la probabilidad de que algún otro equipo lo haga. Contrasta este resultado con los demás que obtuviste arriba.

Tres (3) puntos extra: algo que añade a la mística del Bayer Leverkusen es la cantidad de goles en los últimos minutos que anotaron durante la temporada. El invicto no solo fue improbable: en varios partidos estuvo a punto de romperse y se salvó gracias a un gol tardío. Cuantifiquemos esa fragilidad.

1. Usando datos con el minuto de cada gol (por ejemplo, Understat vía `soccerdata`), identifica todos los partidos en los que el Leverkusen **iba perdiendo después del minuto 85** y anotó para evitar la derrota (empatar o remontar). Llamemos a estos los k partidos “rescatados”.

2. A cada rescate asígna una probabilidad q_i de que realmente ocurriera (por ejemplo, la tasa histórica de la liga de anotar un gol en el minuto 85 o después yendo por detrás, o el estado del partido antes del gol). Calcula la probabilidad conjunta de que *todos* los rescates hayan ocurrido:

$$Q = \prod_{i=1}^k q_i$$

3. Interpreta Q : si esos goles tardíos fueron suerte y no una habilidad repetible, el invicto “sin suerte” habría requerido que todos esos partidos terminaran como derrotas. Es decir, la racha fue aproximadamente $1/Q$ veces más afortunada de lo que sugiere un modelo que toma esos resultados como dados. Reporta el estimado ajustado por suerte

$$\mathbb{P}(\text{invicto ajustado}) \approx \mathbb{P}(\text{invicto}) \times Q$$

donde $\mathbb{P}(\text{invicto})$ es tu resultado del inciso 4 de la lista anterior.

4. **Discute:** ¿es justo llamar “suerte” a estos goles, o anotar de forma repetida en el último minuto refleja un rasgo real y repetible del equipo? No hay una única respuesta correcta; argumenta tu postura.

Nota: Q no debe multiplicarse ingenuamente sobre *toda* la temporada como si fuera un partido más; es un factor que reprocesa *únicamente* los partidos rescatados, midiendo cuánto del invicto dependió de eventos poco probables.

La siguiente simulación deberá ser realizada por todos los grupos:

2.4 Cabo Verde: la nueva cenicienta del fútbol

Para sorpresa de todo el mundo, la selección de Cabo Verde llegó a la Copa Mundial de 2026 y pudo clasificarse a los dieciseisavos de final en un grupo con Uruguay, España y Arabia Saudita, empatando sus 3 partidos y ganándose el corazón de fanáticos alrededor del planeta.

Para sorpresa de nadie, Argentina ganó su partido gracias a varias decisiones arbitrales sospechosas, arruinando la historia de cenicienta del año.

2.4.1 Instrucciones

1. Utilizando el ranking Elo de las selecciones, simula el proceso clasificatorio de Cabo Verde al Mundial. Suponiendo que el repechaje no existe y que la única forma de clasificar es directamente, **¿qué tan improbable fue la clasificación de Cabo Verde?**
2. Luego, simula el grupo que tuvo Cabo Verde en esta Copa del Mundo y encuentra sus probabilidades de clasificarse. Además de esto, contrasta la clasificación que obtuvieron empatando sus tres partidos con los siguientes escenarios:
 - Suponiendo que Uruguay empata o derrota a España.
 - Suponiendo que quedan terceros de grupo (i.e., la probabilidad de clasificar como mejor tercero con tres puntos).
3. Luego, suponiendo que Argentina no hubiera hecho trampa en su partido, estima la probabilidad de que Cabo Verde hubiese derrotado o empatado con Egipto, Suiza, Inglaterra y, por último, España, respondiendo a la pregunta: **¿qué tan probable era que Cabo Verde ganara el Mundial?** (en este escenario, supón que si hay empates Cabo Verde avanza en penales).

3 Entregables

Cada grupo deberá presentar lo siguiente:

1. Repositorio de GitHub con el código donde realizaron las simulaciones, con *commits* que demuestren el trabajo de cada uno de los miembros. Si un miembro no tiene *commits* significativos en el repositorio, **obtendrá un cero en el proyecto**. Tampoco se permitirá que uno o más miembros trabajen únicamente en una parte del proyecto: **todos los miembros deberán contribuir de manera equitativa en ambas simulaciones**.
2. Presentación del evento asignado. Su presentación deberá incluir:
 - Contexto histórico alrededor del evento.
 - Análisis exploratorio de los datos utilizados.
 - Explicación de la metodología y las distribuciones utilizadas.
 - Análisis de resultados.
 - Respuestas a las preguntas centrales del evento.
 - Fuentes utilizadas (bases de datos, libros, librerías, etc.).
3. Presentación de la simulación de los partidos de Cabo Verde, con los mismos requisitos que el punto anterior.

Nota: las presentaciones podrán realizarlas en PowerPoint, el paquete de L^AT_EX **beamer** o Canva. Si realizan la presentación en **beamer**, deberán incluir el código en su repositorio de GitHub.